Subscribe to DeepL Pro to translate larger documents.
Visit www.DeepL.com/pro for more information.

arXiv:2503.10686v2 [cs.CV] 2025年5月7日

MaskAttn-UNet：基于面具注意力机制的通用低分辨率图像分割框架

程安哲[1] , 殷晨中[1] , 张宇[2] , 平恒[1] , 李世轩[1] , 沙欣·纳扎里安(1) , 保罗·博格丹(1) (1) 南加州大学
[2] 不列颠哥伦比亚大学

摘要

*低分辨率图像分割在机器人技术、增强现实及大规模场景理解等实际应用中至关重要，因计算限制导致高分辨率数据往往难以获取。为应对这一挑战，我们提出**MaskAttn**-UNet——一种通过遮罩注意力机制增强传统U-Net架构的新型分割框架。本模型通过选择性强化关键区域并抑制无关背景，显著提升了杂乱复杂场景中的分割精度。不同于传统U-Net变体，MaskAttn-UNet在局部特征提取与广域上下文感知间实现有效平衡，使其特别适用于低分辨率输入。我们在三个基准数据集上对缩放至128×128的输入图像进行评估，结果表明该方法在语义分割、实例分割和全景分割任务中均展现出竞争力。实验结果表明，MaskAttn-UNet在计算成本远低于基于Transformer的模型时，仍能达到与前沿方法相当的精度，使其成为资源受限场景下低分辨率分割的高效可扩展解决方案。*

1. 引言

在复杂场景中实现精确的多类分割对自动驾驶、机器人技术和增强现实等应用至关重要[3, 41, 67]。例如在自动驾驶车辆中，对车辆和行人进行精确的像素级标注是安全导航的基础[9, 13]；而在工业机器人领域，对工具和障碍物的精细分割则能实现可靠的操作执行和有效的避障功能[31, 60]。然而，从低成本监控摄像头到无人机和移动机器人，许多实际视觉系统受限于传感器和硬件能力，只能处理低分辨率图像[1, 30, 63]。这种图像细节的削减给分割算法带来了重大挑战[8, 23, 36, 41]——它们必须在信息严重不足的情况下完成任务。[1, 30, 63]。图像细节的缺失给分割算法带来了重大挑战[8, 23, 36, 41]，这些算法仍需准确区分多种物体类别。因此，亟需开发能在受限条件下保持鲁棒性和精确度的分割方法。

编码器-解码器架构（如U-Net[52]）凭借其多尺度结构，在提取局部特征和精细细节方面表现出色。然而，当单张图像中存在多个物体或类别时[15, 68]，这类架构常难以捕捉长距离依赖关系，导致复杂场景中出现模糊性[51, 58]。相反地，基于Transformer的视觉模型通过自注意力机制整合全局上下文，能够建模像素或区域间的远距离关系[55, 66]。但这种全局表征需付出高昂代价——自注意力机制的二次复杂度导致显著的内存与计算开销，使得此类模型难以应用于嵌入式或实时系统[14, 22]。此外，由于视觉Transformer缺乏卷积神经网络固有的归纳偏置（尤其是局部性偏置），完全基于注意力机制的模型可能忽略区分小型或重叠物体所需的精细细节[6, 50, 65]。这些局限性凸显了亟需一种兼顾局部特征精度、全局上下文捕捉与计算效率的分割方法。

本文提出**MaskAttn-UNet**，这是对U-Net框架的创新性扩展，通过集成新型掩码注意力模块来应对上述挑战。该架构保留了U-Net通过跳跃连接捕捉精细局部细节的优势，同时掩码注意力模块能选择性地强调特征图中的显著区域，从而注入更广泛的上下文信息。通过聚焦相关区域（而非全局关注所有像素），本方法能更高效地捕捉长程依赖关系，并减轻变换器模型常见的内存负担。我们特别针对低分辨率图像设计了该网络架构。

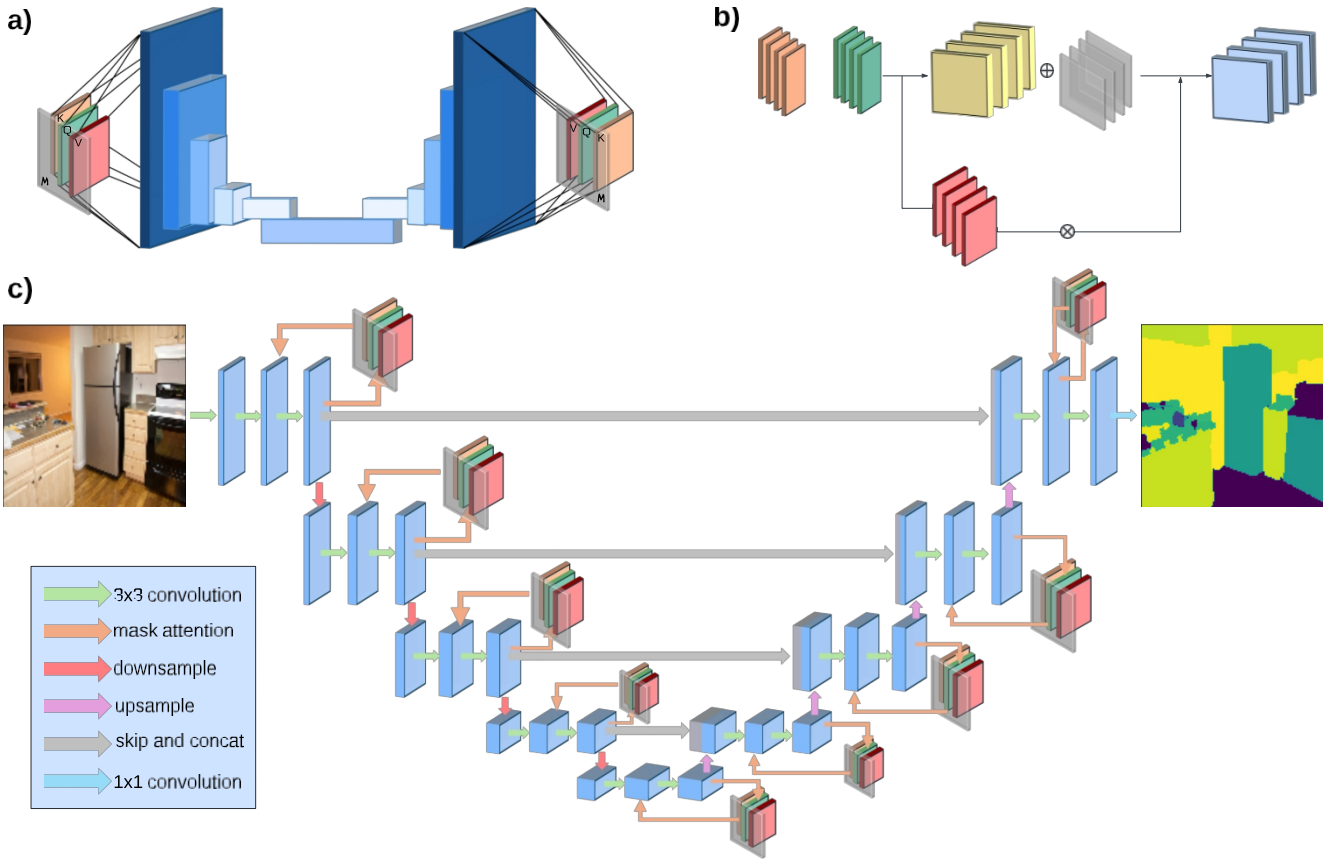

图1. **提出的MaskAttn-UNet概述。**(a) 整体架构包含U-Net编码器-解码器及跳跃连接。(b) 掩码注意力模块通过可学习掩码调节自我注意力。(c) 多尺度编码器-解码器设计包含卷积层、各尺度掩码注意力及编解码器间的跳跃连接。

采用128×128像素的输入图像，在显著降低计算需求的同时，仍能使模型学习到丰富的表示。该设计选择契合现实世界中图像分辨率受限的应用场景，确保MaskAttn-UNet在资源受限的方案中仍能有效运行。

我们在语义分割、实例分割和全景分割任务的标准基准上评估了MaskAttn-UNet。尽管处理相对低分辨率输入，相较于现有最先进方法，本模型在平均交并比(mIoU)、全景质量(PQ)和平均精度(AP)方面均展现出竞争性表现。值得注意的是，MaskAttn-UNet在推理过程中保持适中的内存占用，相较于许多提供相似精度的全变换器模型，其部署实用性显著提升。这些结果表明，我们的混合方法有效融合了卷积归纳偏置与目标自注意机制的优势，能在多样化复杂场景中实现稳健的多类分割。

我们的贡献总结如下：

- 我们提出MaskAttn-UNet——一种基于自注意力机制的U-Net变体...
  一种融合新型掩码注意力模块的算法，可有效捕捉局部细节与长程依赖关系。
- 我们设计了基于128×128输入的低分辨率分割架构，在降低计算需求的同时保持了稳健性能。
- 我们在多个数据集上验证了该方法，相较于基于Transformer的方法，在降低内存消耗的同时实现了分割指标的提升。

这些贡献共同凸显了结合卷积归纳偏好与目标注意力机制在真实世界图谱中实现精准高效分割的价值。

卷积归纳偏置与目标注意力机制相结合，在真实世界图谱中实现精准高效分割的价值。后续章节将探讨启发本方法的相关研究，包括U-Net扩展、视觉Transformer及基于掩膜的分割方法。

2. 相关工作

2.1. U-Net

U-Net[52]引入的编码器-解码器架构已成为图像分割领域的基石。其解码路径包含两条路径：一条收缩路径，通过连续卷积和池化操作提取多尺度特征；另一条扩展路径，利用上采样层恢复空间分辨率。

解码器由收缩路径和扩展路径组成：收缩路径通过连续卷积与池化操作提取多尺度特征，扩展路径则借助上采样层恢复空间分辨率。编码器与解码器中对应层间的跳跃连接，使网络能够融合深层语义信息与高分辨率空间细节。该结构在生物医学分割等要求精准定位的应用中已展现出显著成效[5, 27, 52, 61]。

尽管取得成功，标准卷积层固有的固定感受野限制了U-Net捕捉长程依赖关系的能力[24, 44, 64]。在包含多个交互对象或重叠结构的场景中，这可能导致分类错误或不同区域的合并[42, 53, 62]。为解决这些局限，已提出多种扩展方案。例如注意力U-Net[43]引入注意力门机制优化跳跃连接，使模型能选择性强调相关特征。类似地，残差U-Net[69]通过残差连接促进深度网络训练。尽管这些改进优化了梯度传播与局部特征提取，却未能完全解决跨图像聚合全局上下文的难题。

2.2. Swin Transformer

基于Transformer的模型凭借其通过自注意力机制建模长程依赖的能力，已成为图像分割领域强大的替代方案[33, 54, 66]。Swin Transformer[37]通过采用分层架构实现了该领域的重大突破。该模型将输入图像划分为互不重叠的图像块，并在局部窗口内计算自注意力。其关键创新在于引入层间偏移窗口机制，既实现了跨窗口交互，又有效扩展了感受野范围，同时避免了全局注意力计算的高昂成本。这种分层设计促进了多尺度特征学习，使Swin既能处理高分辨率图像，又能平衡局部细节与全局上下文。

然而，这些优势需要付出巨大的计算代价。内存需求和处理要求的增加——尤其在更深的配置或更大的输入规模下——可能对实时推理或在资源受限硬件上的部署构成障碍[29, 40, 59]。因此，在分割性能与效率之间寻求平衡，仍是基于Transformer方法的活跃研究课题。

2.3. Mask2Former

Mask2Former[17]在MaskFormer[16]框架基础上，将分割问题重新定义为集合预测问题。MaskFormer通过为图像中每个物体分配唯一遮罩实现分割实例分配唯一遮罩，从而统一处理"事物"与"物品"。Mask2Former通过引入动态注意力遮罩机制进行优化，该机制能自适应聚焦相关图像区域，使模型得以有效分离重叠物体，并生成高质量的实例分割与全景分割输出。

Mask2Former中的动态掩码生成机制在捕捉全局上下文信息的同时，仍能灵活勾勒物体边界。然而，仅依赖注意力机制可能导致精细局部细节的丢失，而这些细节对于精确边界划分至关重要，尤其在包含微小物体或复杂纹理的场景中[4, 18, 70]。尽管存在这些挑战，Mask2Former在标准分割基准测试中仍展现出强健性能。其设计凸显了基于掩码的注意力机制在弥合局部精度与全局上下文差距方面的潜力，尽管计算复杂度和训练数据需求仍是亟待改进的领域。

3. 方法

在本节中，我们将详细描述所提出的分割方法。该方法通过处理输入图像生成像素级分类掩膜，其中每个像素被分配语义标签。为扩展方法能力，我们还整合了实例分割与全局分割分支，它们分别利用共享特征表示和专用损失函数。首先概述模型整体架构，随后阐述训练目标与优化流程。

3.1. 架构概述

MaskAttn-UNet网络采用编码器-解码器架构，并在多尺度上集成掩码注意力模块。编码器通过逐级卷积模块提取分层特征，逐步降低空间分辨率。在每个尺度上，特征由掩码注意力模块进行精炼，该模块生成可学习的二值掩码以抑制无信息区域并突出显著结构。跳跃连接将编码器与解码器的对应层相连，助力解码器在分割输出中恢复高分辨率细节。解码器通过逐步上采样并融合特征（经跳跃连接增强），最终生成预测结果。

图1展示了该架构的整体概览。图1(a)展示了整体U-Net风格的处理管道。图1(b)阐释了掩码注意力模块的内部结构，该模块通过可学习的注意力掩码增强特征表示。图1(c)呈现了详细的多尺度编码器-解码器设计，包括各分辨率层级中卷积层、跳跃连接及掩码注意力块的布局。

3.2. 掩码注意力模块

每个掩码注意力模块借鉴多头自注意力机制，并引入可学习的掩码层来调节注意力权重。对于来自编码器或解码器的输入特征图X，我们首先将其重塑为

$X \in \mathbb{R}^{B\times H\times W\times C}$，其中B为批量大小，$H \times W$为空间维度，C为通道数。

随后我们应用多头掩码自注意力机制（在我们的实现中使用四个注意力头）。注意力权重通过缩放点积注意力机制计算，并附加掩码矩阵M：

$$\mathrm{MaskAttn}(Q, K, V, M) = \mathrm{Softmax}\left(\frac{QK^T}{\sqrt{d_k}} + M\right)V \tag{1}$$

其中 $Q = XW^Q$，$K = XW^K$，$V = XW^V$，且 d_k 是查询向量和键向量的维度。这里，

M 是可学习（或动态计算）的掩码，其满足

抑制了注意力矩阵中无信息区域的贡献。直观而言，M使注意力偏向于聚焦于相关的空间位置。

随后将给定头部的注意力运算结果在所有头部间进行组合（如多头注意力机制），并通过残差连接添加至原始输入。设A表示掩码多头注意力的结果

（合并头部后）。我们将A输入到采用GELU非线性函数的两层前馈网络（FFN）中，并添加

最终残差A为：

$$A_{\mathrm{out}} = \mathrm{GELU}(AW_1 + b_1)W_2 + b_2 + A \tag{2}$$

其中 W_1, W_2 为权重矩阵，b_1, b_2 为全连接层的偏置项。这最终生成遮罩注意力模块的输出 A_{out}。遮罩自注意力机制的组合残差FFN通过整合全局上下文增强特征表示，同时保留通过跳跃连接传递的原始信息。

3.3. 分割损失

我们采用复合损失函数优化网络，该函数结合了语义分割损失与实例级对比损失。平衡这两项目标使模型能够同时学习像素级别的类别区分与实例特有的可分离性。

语义分割损失。对于语义分割任务，其中每个像素属于C类中的某一类，我们采用标准的交叉熵损失。设y_{ij}为像素(i, j)的真实类别标签，$p_{ij}(c)$为像素(i, j)属于类别c的预测概率。损失函数为：

$$L_{\mathrm{CE}} = -\sum_{i,j}\sum_{c=1}^{C} \delta[y_{ij} = c] \log p_{ij}(c), \tag{3}$$

其中$\delta[\ ]$为克罗内克尔δ函数（当参数为真时取值1，否则为0）。这种像素级交叉熵机制能有效激励对每个像素进行正确的类别预测。

实例对比损失。对于实例分割（以及全景分割中的实例组件），我们采用对比嵌入损失，该损失机制鼓励同一物体实例的像素具有相似的特征嵌入，同时将不同实例的像素嵌入推离。设$e_{(ij)}$表示网络生成的像素(i, j)的嵌入向量。对于给定像素(i, j)，定义$P_{(ij)}$为正样本像素索引集（即与(i, j)属于同一真实实例的像素），$N_{(ij)}$为负样本像素索引集（即属于其他实例的像素）。

不同实例）。我们首先计算规范化因子 D_{ij} 在所有考虑的 (i, j) 对：

$$D_{ij} = \sum_{(m,n)\in P_{ij}\cup N_{ij}} \exp\frac{e_{ij}\cdot e_{mn}}{\tau}, \tag{4}$$

其中τ是控制对比分布锐度的温度参数。对于正对(i, j)和$(k, l) \in P_{ij}$（即来自同一实例的两个像素），每对对比损失为：

$$l_{ij,kl} = -\log\frac{\exp\frac{e_{ij}\cdot e_{kl}}{\tau}}{D_{ij}}。 \tag{5}$$

该机制通过惩罚模型实现：当嵌入向量e_{ij}与e_{kl}的相似度（分子）相对于所有其他向量对（分母）未显著提升时，模型将承受损失。像素(i, j)的实例对比损失通过以下步骤计算：先对所有正样本配对(k, l)的$l_{ij,kl}$取平均值$P_{(ij)}$，再对所有像素求平均：

$$L_{\mathrm{IC}} = \frac{1}{N}\sum_{(i,j)}\frac{1}{|P_{ij}|}\sum_{(k,l)\in P_{ij}} l_{ij,kl}, \tag{6}$$

其中 N 为考虑的总像素数（为提高效率，可取所有像素对的抽样子集）。实际应用中，L_{IC} 促使同一实例的嵌入在特征空间中聚类，而不同实例的嵌入保持分离。最终分割损失为两部分的加权和：

$$L_{\mathrm{seg}} = L_{\mathrm{CE}} + \lambda L_{\mathrm{IC}}, \tag{7}$$

其中 λ 控制语义分割损失与实例对比损失之间的平衡。在我们的实验中，我们通过调整 λ 确保两项均不占主导地位，从而使模型能够同时学习精确的像素级分类和清晰分离的实例嵌入。（关于 λ 选择的详细说明见附录 B.1。）

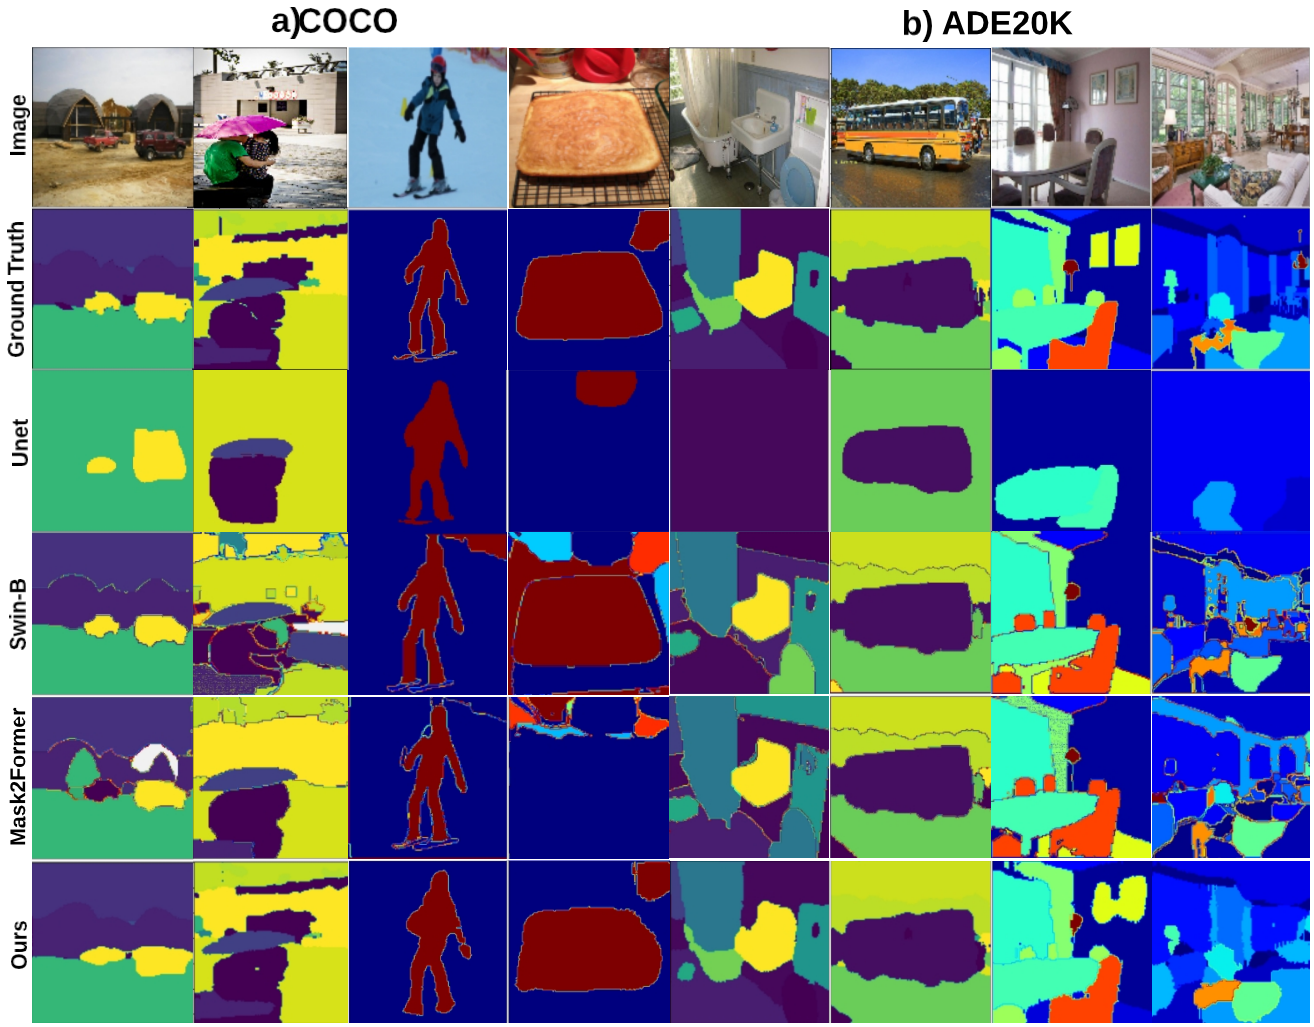

图2. **(a) COCO和(b) ADE20K数据集上的分割结果可视化。**每个数据集中，左侧两列展示语义分割结果，右侧两列展示实例分割结果。每组图块顶部为输入图像，其后依次为地面实测值和不同方法的预测结果。

4. 实验

我们在三个常用分割基准上评估MaskAttn-UNet模型，报告其语义分割、实例分割和全景分割结果。随后将本模型与全景分割领域最先进方法进行对比，并通过不同比例训练数据集检验其性能。这些实验验证了掩码注意力模块的设计选择，并证明MaskAttn-UNet具备跨数据集泛化能力。

数据集我们采用三种广泛应用的多任务图像分割基准数据集。COCO[35]是包含80类"物体"与多类"背景"的大规模数据集，支持语义分割、实例分割及全局分割任务。ADE20K[71]包含150类语义标签（100类"物体"与50类背景）。Cityscape数据集[19]专注于城市街道场景，包含19个类别（8个"物体"和11个"杂物"），常用于自动驾驶场景中的语义分割与全景分割。 所有图像均缩放为128×128像素以减少计算开销，并模拟某些实际应用中遇到的低分辨率条件。

评估指标。我们为每项任务采用标准评估指标。针对*语义分割*任务，我们报告平均交并比（mIoU）[21]，该指标衡量预测区域与真实区域之间各类别的平均重叠程度。*实例*分割采用不同交并比阈值下的平均精度(**AP**)指标[35]，评估单个物体实例的检测与分割效果（AP值越高表明精确度与召回率的权衡越优）。*全景分割则*采用

全视图质量（**PQ**）指标[34]，该指标综合评估"事物"与"物品"类别的识别质量（RQ）和分割质量（SQ）。同时在100% mIoU阈值下报告mIoU和AP值。这些指标为每个数据集的分割性能提供了全面评估。

4.1. 实现细节

我们的实现基于U-Net骨干网络，包含四个下采样编码器阶段和四个上采样解码器阶段，通过跳跃连接恢复空间细节。编码器逐步将特征通道数从64增加至128再至256（其中两个模块为256通道），最终进入瓶颈层以压缩并提炼全局上下文信息。解码器随后进行对称上采样，通过缩减通道维度并融合对应编码器层级的特征图，在输出中重建精细的空间细节。

在每个编码器和解码器阶段，我们都融入了第3.2节所述的MaskAttn模块。每个模块包含一个可学习的二进制掩码，可选择性地抑制无关激活。这使网络能够聚焦于重要区域，例如物体边界和显著结构，即使在低分辨率特征图中亦然。通过在整个网络中集成这些模块，MaskAttn-UNet既保留了卷积对局部性的归纳偏好，又获得了在每个尺度上捕捉长程依赖关系的能力（更详细的分析见附录B.3）。

指标	COCO	ADE20K	城市景观
mIoU↑ (%)	43.7	44.1	67.4

表1. **在COCO（133类）、ADE20K（150类）和Cityscapes（19类）数据集上的语义分割结果。**我们的模型在各类数据上均取得显著成效。

4.2. 训练设置

损失函数。我们通过选择第3.3节定义的损失函数，分别训练模型的所有分支（语义、实例、全景）。对于语义分割，我们采用交叉熵损失（式3），该损失能提供强有力的像素级分类信号。针对实例分割与全景分割，我们引入实例对比损失（式6）以学习独特的对象嵌入。实践中，我们还为每个预测实例添加标准分类损失项（用于预测其语义类别），确保每个实例嵌入与特定类别关联。通过平衡$L_{(CE)}$与$L_{(IC)}$的权重（式7中λ取值0.5），模型可同时学习类级别的区分度与精细的实例分离能力。**训练设置。**我们在1000个 epoch上训练模型。

每个数据集。所有图像均统一缩放为128×128像素。

在语义分割实验中，我们使用两块30GB NVIDIA V100 GPU，批量大小为8。针对内存需求更高的实例分割和全景分割实验，则采用两块40GB NVIDIA A100 GPU，批量大小为14。模型通过AdamW优化器进行训练，初始学习率设定为5×10^{-4}，权重衰减率为10^{-3}。

AdamW优化器进行优化，初始学习率设为5×10^{-4}，权重衰减率为10^{-3}。我们采用数据增强技术，包括随机缩放抖动和水平翻转操作旨在提供输入多样性，同时避免过度复杂化训练分布。这些训练配置经过精心选择，旨在平衡每项任务的内存使用与吞吐量，从而在不同的分割目标间实现一致的收敛效果。

数据集	AP@30	AP@50	AP@70	AP@100
COCO	35.0	31.6	31.3	30.2
ADE20K	33.8	33.2	30.5	30.5
城市景观	38.9	36.6	36.2	35.5

表2. **实例分割结果（AP@k）。**k代表mIoU阈值。即使采用较低阈值，MaskAttn-Unet仍保持稳定表现。这表明所提模型能可靠地隔离并勾勒出独立物体实例。

4.3. 主要结果

语义分割。我们使用COCO `panoptic val2017`、`ADE20K` val和Cityscapes val数据集评估语义分割模型，所有标签均经过专门处理以满足语义分割需求。如表1所示，MaskAttn-UNet在COCO上达到43.7%的mIoU，在ADE20K上达到44.1%，在Cityscapes上达到67.4%。这些结果表明，尽管输入分辨率较低，该网络仍能高效融合全局上下文信息与局部空间细节。在图2(a)和图2(b)左侧两列的分割图中，可见物体边界得到良好保留，复杂纹理区域的分割清晰可辨。尤其在处理重叠物体或精细结构细节的区域时表现优异。这表明掩膜注意力机制成功抑制了背景噪声，并增强了学习特征的辨别能力。

数据集	mIoU↑ (%)	AP↑ (%)	PQ↑ (%)
COCO	45.3	31.5	35.7
ADE20K	45.9	30.7	33.6
城市景观	70.1	35.5	58.3

表3. **Panoptic在COCO、ADE20K和Cityscapes上的分割性能。**MaskAttn-UNet在多样化数据集上展现出强大的分割能力。

此外，对分割结果的深入分析表明，该网络能很好地适应不同场景的复杂性。

方法	浮点运算次数 (G)	参数数量 (M)	COCO			ADE20K			Cityscapes		
			mIoU↑	PQ↑	AP↑	mIoU↑	PQ↑	AP↑	mIoU↑	PQ↑	AP↑
U-Net	4	32	33.8	20.1	13.8	37.3	24.1	16.5	63.4	51.2	27.9
DETR-R50	86	41	34.7	25.3	16.7	40.7	26.5	21.0	66.6	53.7	30.6
DETR-R101	152	60	35.3	27.4	18.8	41.1	27.4	21.9	67.4	54.2	32.2
Mask2Former-R50	226	**44**	38.1	31.4	27.3	45.2	33.4	29.1	69.3	55.7	34.3
Mask2Former-R101	293	63	39.2	31.7	28.1	45.7	**33.9**	30.5	**71.4**	57.2	35.4
MaskAttn-UNet（我们的）	**11**	46	**45.3**	**35.7**	**31.5**	**45.9**	33.6	**30.7**	70.1	**58.3**	**35.5**

表4. **MaskAttn-UNet与顶尖全视域分割模型的**对比MaskAttn-UNet在显著降低计算复杂度（体现在减少的浮点运算次数和参数数量）的同时，实现了具有竞争力的分割性能。这种高效性凸显了其在需要平衡精度与资源约束的应用场景中的潜力。最佳结果以**粗体**标注，次优结果以下划线标注。

复杂性。尤其在光照与对比度条件多变的图像中（图2(b)首图），该网络始终保持高精度，确保大面积均匀区域与细微复杂细节均能准确标注。掩码注意力模块的设计似乎能选择性放大关键特征，同时降低信息量较低区域的干扰，从而在不同类别和挑战性场景中实现更一致的预测结果。

实例分割。实例分割性能在COCO `val2017`、ADE20K val和Cityscapes val数据集上进行评估，所有标签均针对任务需求进行优化。表2总结了MaskAttn-UNet的性能表现。在COCO数据集上，该模型在IoU阈值30时达到35.0%的平均精度(AP)，在IoU阈值100时降至30.2%。ADE20K数据集对应AP值分别为33.8%、33.2%、30.5%和30.5%（IoU阈值分别为30、50、70、100）；Cityscapes数据集对应AP值为38.9%、36.6%、36.2%和35.5%。这些结果表明，即使在物体重叠或密集排列的场景中，MaskAttn-UNet 也能可靠地隔离和描绘单个物体实例。

调整交并覆盖率阈值的效果揭示了网络处理不同实例复杂度的能力。较低的交并覆盖率阈值主要捕获最突出的物体，从而获得更高的平均精度值；而较高的交并覆盖率阈值则将检测范围扩展至较小或部分遮挡的实例，导致平均精度略有下降。如图2(a)和图2(b)右侧两列所示的实例分割输出可视化结果表明，掩码注意力模块有助于多尺度特征图的精细化处理，从而提升相邻物体的分离度及精细结构细节的识别能力。例如图2(b)中第三张图像的分割结果显示，MaskAttn-UNet在物体重叠和边界复杂的区域显著减少了误检。该网络能在杂乱区域保持物体轮廓，确保独立实例的分离度始终如一。这些实验结果表明，所提出的架构能够很好地适应各种真实世界条件，这进一步证明了其在实际实例分割应用中的有效性。

全景分割。全景分割性能在COCO `panoptic val2017`、ADE20K val和Cityscapes val数据集上进行了评估。表3展示了结果：在COCO数据集上，MaskAttn-UNet模型针对"物体"区域实现了45.3%的平均交并比(mIoU)，针对"事物"实例实现了31.5%的平均精度(AP)，整体泛视图质量(PQ)达35.7%。在ADE20K数据集上，该模型达到mIoU 45.9%、AP 30.7%和PQ 33.6%的成绩。在 Cityscapes 数据集上，该模型分别达到 70.1% 的 mIoU、35.5% 的 AP 和 58.3% 的 PQ。这些结果表明，MaskAttn-UNet 在前景物体和背景区域的分割性能上均表现均衡。

在Cityscapes数据集上获得的高mIoU值表明，该网络有效利用了城市场景的结构化特性，实现了稳定的背景分割效果。同时，在COCO和ADE20K数据集上稳定的AP值和PQ值，证明了其处理多样化复杂场景的能力。稳健的背景分割与精准的实例边界划分相结合，共同促成高PQ值，印证了该网络提供全面场景理解的能力。

与基线模型的比较。为验证方法的鲁棒性，我们在COCO、ADE20K和Cityscapes三大数据集上，将本模型与多个复杂度相当或略高的尖端模型进行基准测试（见表4）。例如，相较于运行于4G浮点运算且拥有3200万参数的U-Net，MaskAttn-UNet在COCO数据集上实现了mIoU提升**10%以上**、PQ提升15%、AP提升**近**20%的性能，而参数数量仅增加了约1500万。尽管U-Net较低的浮点运算量在简单场景中具有优势，但在存在物体重叠和复杂纹理的环境中表现欠佳。相比之下，MaskAttn-Unet仅需11G浮点运算量和4600万参数，便能有效捕捉精细空间细节，并更高效地处理杂乱场景。

捕捉精细空间细节，并更高效地处理杂乱场景。

我们还评估了基于DETR的模型，包括DETR-R50（86G浮点运算，4100万参数）和DETR-R101（*152G*浮点运算，6000万参数）。基于DETR的模型同样需要更高的计算成本，但性能提升有限，这限制了它们在资源受限或实时场景中的应用。

此外，Mask2Former-R50需要高达*226G* FLOPs，而采用ResNet-101骨干网络的Mask2Former-R101则需要更多计算资源。值得注意的是，Mask2Former-R101相较于Mask 101主干结构，所需计算资源更为庞大。值得注意的是，Mask2Former-R101相较于MaskAttn-UNet仅获得微弱提升——在ADE20K数据集上PQ值高出0.3%，Cityscapes数据集上mIoU高出1.3%。然而这些微小收益代价高昂：Mask2Former-R101的参数数量比MaskAttn-UNet多出1700万（增幅约37%），这表明单纯增加计算量未必能显著提升分割质量。总体而言，MaskAttn-UNet在准确率与效率之间实现了良好平衡，使其成为计算资源受限场景下的实用选择。

少量样本训练。在许多实际场景中，收集大量标注数据集既耗费成本又耗费时间。为评估训练数据规模对分割性能的影响，我们在COCO `panoptic` val2017数据集上测试了MaskAttn-UNet模型，采用不同比例（10%、25%、50%、75%和100%）的完整数据集进行训练。如图3所示，结果呈现以下趋势：

- **10%训练数据：**模型达到36.7% mIoU、25.3% PQ和22.6% AP。尽管指标未达最优，但证明网络在数据稀缺条件下仍能提取有效特征。
- **25%训练数据：**性能提升至37.3% mIoU、27.6% PQ和25.1% AP，表明训练数据的适度增加能显著提升分割精度。
- **50%训练数据：**模型达到40.1% mIoU、33.3% PQ和29.4% AP，表明仅需完整数据集的一半即可学习到稳健的特征表示。
- **75%训练数据：**指标进一步提升至43.4% mIoU、35.1% PQ和30.1% AP，证实增加数据在保持高效学习动态的同时持续提升模型性能。
- **100%训练数据：**利用完整数据集时，模型达到45.3%的mIoU、35.7%的PQ和31.5%的AP，彰显其充分利用现有标注数据实现最佳分割结果的能力。

这些趋势凸显了MaskAttn-UNet强大的数据效率，使其成为标注数据有限场景下的实用选择。值得注意的是，该模型在数据可用性提升时展现出显著性能提升，符合描述神经网络性能随数据集规模变化的经典神经网络扩展规律[2,32]。这种数据效率在医疗场景中尤为珍贵。随着数据可用性的提升，其性能显著增强，符合描述神经网络性能随数据集规模扩展规律的经典神经网络扩展法则[2,32]。这种数据效率在医学图像计算等获取大规模标注数据集困难的领域尤为珍贵[48,56]。因此，MaskAttn-UNet在训练数据减少时仍能有效运作的能力，使其成为数据受限环境下的可行解决方案。

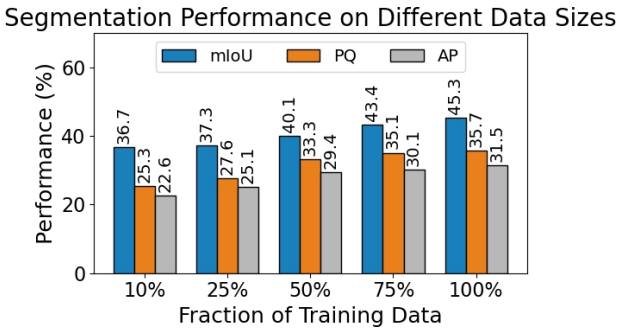

图3. **MaskAttn-UNet在不同比例（10%、25%、50%、75%、100%）的`panoptic` train2017数据集上的分割性能。**结果表明随着数据集规模增大，各项指标均呈现持续提升，凸显了该模型卓越的数据效率。

5. 讨论

我们提出MaskAttn-UNet模型，通过将掩码注意力模块融入传统U-Net架构，实现了分割模型的重要突破，有效增强了局部与全局特征提取能力。这种混合方法既发挥了卷积网络建模局部上下文的优势，又利用了掩码注意力机制处理长距离依赖关系的能力。我们在COCO、ADE20K和Cityscapes等数据集上的实证评估表明，MaskAttn-UNet不仅持续超越标准U-Net模型，与Mask2former等基于Transformer的架构相比，还显著降低了计算资源消耗。这些发现凸显了选择性注意力机制在低分辨率分割任务中的潜力，弥合了卷积网络的效率优势与变换器模型全局上下文感知能力的差距。

尽管成果令人鼓舞，仍有改进空间。后续工作将聚焦于将MaskAttn-UNet扩展至医学影像等领域——该领域因数据稀缺性及精确边界划定需求而面临独特挑战。此外，将MaskAttn-UNet集成至扩散模型可增强生成与数据增强过程。处理微小物体及精细细节的分割仍是活跃研究领域；引入

专用模块或定制损失函数有望进一步提升性能。这些未来方向旨在优化MaskAttn-UNet的能力，并拓展其在各类真实分割场景中的适用性。

参考文献

[1] 安德烈亚斯·阿克伯格、卡马尔·纳斯罗拉希与托马斯·B·穆斯隆德。监控摄像头人脸图像的真实世界超分辨率处理。《IET图像处理》，16(2):442– 452，2022年。

[2] 易卜拉欣·阿卜杜勒穆赫辛、贝纳姆·内沙布尔、翟晓华。语言与视觉领域神经尺度律的再探。神经信息处理系统进展，35:22300–22312, 2022. 8

[3] 努夫·阿卜杜拉·穆贾利、比斯玛·里亚兹·丘格泰、奈夫·穆达维、阿卜杜勒瓦哈卜·阿扎布、阿萨德·阿尔加尼、哈姆丹·阿扎拉尼、朴正敏。基于多目标分割与卷积神经网络的Unet物体识别模型。《计算机、材料与连续体》，80(1)，2024。 1

[4] 拉杰什·安卡雷迪与拉达克里希南·德里巴布。基于深度学习的城市场景密集分割技术综述： 解析。IEEE Access，2025。3

[5] Reza Azad, Ehsan Khodapanah Aghdam, Amelie Rauland, Yiwei Jia, Atlas Haddadi Avval, Afshin Bozorgpour, Sanaz Karimijafarbigloo, Joseph Paul Cohen, Ehsan Adeli, and Dorit Merhof. 医学图像分割综述：U-Net的成功. *IEEE模式分析与机器智能汇刊*, 2024. 3

[6] 阿西什·贝拉、扎卡里·沃顿、刘永怀、尼克·贝西斯和阿尔登杜·贝赫拉。注意力引导网络（ag-net）：基于关键点驱动的注意力机制的图像识别深度网络。《IEEE图像处理汇刊》，30卷：3691–3704页，2021年。1

[7] 扬·贝兰。长程依赖性。《威利跨学科评论：计算统计学》，2(1):26–35, 2010. 14

[8] Bir Bhanu, Sungkee Lee, and John Ming. 基于遗传算法的自适应图像分割. *《IEEE系统、人与控制论汇刊》*, 25(12):1543–1567, 1995. 1

[9] 巴拉特·巴蒂亚与普拉文·莫迪. 自动驾驶汽车的道路图像分割 . 2023. 1

[10] 乔治·E·P·博克斯、格威林·M·詹金斯、格雷戈里·C·赖因塞尔与格蕾塔·M·吕恩。时间序列分析：预测与控制。约翰威立出版社，2015年。15

[11] 罗伯特·M·布莱斯与凯文·B·斯普拉格。重新审视去趋势波动分析。科学报告，2(1):315，2012年。14

[12] 安娜·卡博内、朱利亚诺·卡斯特利、H·尤金·斯坦利。金融时间序列中的时变赫斯特指数。《物理学A：统计力学及其应用》，344 (1-2):267–271, 2004. 14

[13] 陈龙标、何鑫、赵先涛、李涵、黄云怡、周斌斌、陈伟、李永川、温成璐、王成。Gocomfort：基于高精度道路损伤众感知的自动驾驶舒适导航。IEEE移动通信汇刊，22(11):6477–6494，2022。

损伤众包感知实现*舒适导航*。*IEEE移动计算汇刊*，22(11):6477–6494, 2022. 1

[14] 陈天琪、徐冰、张池远、Carlos Guestrin。亚线性内存成本下的深度网络训练。*arXiv预印本 arXiv:1604*.06174，2016年。1

[15] 陈云、谢一恒、姚伟远、张宇、王新红、杨艳丽、唐玲玲. U-mga：基于多尺度全局注意力机制优化多模块Unet的耕地精细化分割模型. *遥感*, 17(5):760, 2025. 1

[16] 程博文、Alex Schwing、Alexander Kirillov. 像素级分类并非语义分割的全部需求. *神经信息处理系统进展*, 34:17864–17875, 2021. 3

[17] 程博文、伊尚·米斯拉、亚历山大·G·施温格、亚历山大·基里洛夫、罗希特·吉尔达尔。通用图像分割的掩码注意力掩码变换器。收录于IEEE/CVF计算机视觉与 模式识别会议论文集，第1290–1299页，2022年。

[18] 朱洪湖、陈邦乔。基于多尺度级联网络的高分辨率图像精细裂缝分割。*计算机辅助土木与基础设施*工程，39(4):575–594，2024。3

[19] Marius Cordts, Mohamed Omran, Sebastian Ramos, Timo Rehfeld, Markus Enzweiler, Rodrigo Benenson, Uwe Franke, Stefan Roth, Bernt Schiele. 城市景观语义理解数据集. *见IEEE计算机视觉与模式识别会议论文集*, 第3213–3223页, 2016. 5

[20] 詹姆斯·德宾与杰弗里·S·沃森。最小二乘回归中序列相关性检验：I。《生物计量学》，37(3/4): 409–428, 1950. 15

[21] 马克·埃弗林厄姆、阿里·埃斯拉米、卢克·范古尔、克里斯托弗·K·I·威廉姆斯、约翰·温恩、安德鲁·齐瑟曼。《帕斯卡视觉对象分类挑战赛：回顾性研究》。《国际计算机视觉杂志》，111:98–136，2015。 5

[22] Michael J Feeley, William E Morgan, EP Pighin, Anna R Karlin, Henry M Levy, Chandramohan A Thekkath. 工作站集群中的全局内存管理实现. *收录于第十五届ACM计算机系统原理研讨会论文集*，第201–212页，1995年. 1

[23] 斯瓦伦杜·戈什、尼巴兰·达斯、伊希塔·达斯、乌吉瓦尔·毛利克。理解图像分割的深度学习技术。ACM计算调查（CSUR），52(4):1–35， 2019。1

[24] 郭志玲、卢佳悦、陈琪、刘正光、宋晨晨、谭洪军、张昊然、严金月。Transpv：基于视觉变换器的深度学习模型提升光伏板检测精度。应用能源，355:122282，2024。3

[25] C Heneghan 与 G McDarby. 建立趋势波动分析与功率谱密度分析在随机过程中的关联性. *物理评论E*, 62 (5):6103, 2000. 14

[26] 胡坤、普拉门·伊万诺夫、陈志、佩德罗·卡佩纳、H·尤金·斯坦利。趋势对去趋势波动分析的影响。《物理评论E》，64(1):011114，2001。14

[27] 黄鲁哲、肖雄业、李世轩、孙佳雯、黄毅、奥兹坎·艾多甘、保罗·博格丹。用于微观图像修复的多尺度条件生成模型。2024. 3

[28] Harold Edwin Hurst. 水库长期蓄水能力. *美国土木工程师学会学报*, 116(1):770–799, 1951. 14

[29] 贾天宇、居宇浩、Russ Joseph、顾杰. Ncpu：面向实时端到端性能的资源受限低功耗设备嵌入式神经CPU架构. *2020年IEEE/ACM第53届国际微体系结构研讨会(MICRO)*, 1097–1109页. IEEE, 2020. 3

[30] 帕比特拉·乔希、卡兰舍尔·S·桑杜、古里克巴尔·辛格·迪隆、陈建利和凯拉什·博哈拉。利用无人机检测与监测小麦病害。农业计算机与电子学，224:109158，2024。1

[31] Md Mohsin Kabir, Jamin Rahman Jim, Zolta´n Istenes. 自动驾驶导航中的地形检测与分割：前沿系统综述. *信息融合*, 113:102644, 2025. 1

[32] Jared Kaplan, Sam McCandlish, Tom Henighan, Tom B Brown, Benjamin Chess, Rewon Child, Scott Gray, Alec Radford, Jeffrey Wu, Dario Amodei. 神经语言模型的标度律. *arXiv预印本arXiv:2001.08361*, 2020. 8

[33] 萨尔曼·汗、穆扎马尔·纳西尔、穆纳瓦尔·哈亚特、赛义德·瓦卡斯·扎米尔、法哈德·沙巴兹·汗、穆巴拉克·沙赫。《视觉中的Transformers：综述》。ACM计算 调查(CSUR)，54(10s):1–41，2022年3月

[34] Alexander Kirillov, Kaiming He, Ross Girshick, Carsten Rother, 及 Piotr Dolla´r. 全景分割. *收录于IEEE/CVF计算机视觉 与模式识别会议论文集*, 第9404–9413页, 2019. 6

[35] 林宗毅、迈克尔·迈尔、塞尔吉·贝隆吉、詹姆斯·海斯、皮耶特罗·佩罗纳、德瓦·拉马南、皮奥特·多拉尔、劳伦斯·齐特尼克。*微软COCO：上下文中的常见物体。载于《计算机视觉——ECCV 2014：第13届欧洲会议论文集》，瑞士苏黎世，2014年9月6-12日，第V卷第13册*，第740–755页。Springer出版社，2014年。5

[36] Geert Litjens, Robert Toth, Wendy Van De Ven, Caroline Hoeks, Sjoerd Kerkstra, Bram Van Ginneken, Graham Vincent, Gwenael Guillard, Neil Birbeck, Jindang Zhang 等. 《MRI前列腺分割算法评估：PROMISE12挑战赛》。*《医学图像分析》*, 18(2):359–373, 2014. 1

[37] 刘泽，林宇彤，曹悦，胡涵，魏一轩，张征，林斯蒂芬，郭柏宁。Swin Transformer：基于移位窗口的分层视觉变换器。*IEEE/CVF国际计算机视觉会议论文集*，第10012–10022页，2021年。3

[38] 贝诺伊特·B·曼德尔布罗特与詹姆斯·R·沃利斯。重标度范围r/s在非周期性长期统计依赖性测量中的稳健性。《水资源研究》，5(5): 967–988, 1969. 14

[39] Rainer Martin. 基于最优平滑与最小统计量的噪声功率谱密度估计. *IEEE语音与音频处理汇刊*，9(5):504–512, 2001. 14

[40] 阿纳布·尼利姆·马祖姆德、孟健、哈西布-阿尔·拉希德、乌特杰·卡拉库里、张鑫、徐载善、蒂努什·莫赫塞宁。基于微AI设备端推理的神经网络加速器优化综述。*IEEE电路与系统新兴与精选专题期刊*，11 (4):532–547, 2021. 3

[41] 谢尔文·米纳伊、尤里·博伊科夫、法蒂赫·波里克利、安东尼奥·普拉萨、纳赛尔·凯塔纳瓦兹、德米特里·特尔佐普洛斯。基于深度学习的图像分割：综述。IEEE模式分析与机器智能汇刊，44(7):3523– 3542，2021。1

[42] 南亮亮、谢可、安德烈·沙夫。基于搜索-分类的杂乱室内场景理解方法。《ACM图形学杂志》（Transactions on Graphics），31(6):1–10，2012年。

[43] 奥赞·奥克泰、约·施莱姆珀、洛伊克·勒·福尔戈克、马修·李、马蒂亚斯·海因里希、三泽和成、森健作、史蒂文·麦克多纳、尼尔斯·哈默拉、伯恩哈德·凯因茨等。注意力U-Net：学习胰腺定位策略。arXiv预印本arXiv:1804.03999，2018年。3

[44] 潘少彦、雷阳、王同和、雅各布·温恩、张志伟、贾斯汀·罗珀、阿谢什·B·贾尼、普雷特什·帕特尔、杰弗里·D·布拉德利、刘天等。基于令牌式Transformer卷积神经网络的男性骨盆多器官分割。物理医学与生物学，，67(20):205012，2022。3

[45] 彭志康、谢尔盖·V·布尔德列夫、施洛莫·哈夫林、迈克尔·西蒙斯、H·尤金·斯坦利、阿里·L·戈德伯格。DNA核苷酸的马赛克组织结构。《物理评论E》，49(2): 1685, 1994. 14

[46] Talmo D Pereira, Nathaniel Tabris, Arie Matsliah, David M Turner, Junyu Li, Shruthi Ravindranath, Eleni S Papadopoulou, Edna Normand, David S Deutsch, Z Yan Wang 等. Sleap：多动物姿态追踪深度学习系统. *自然方法*, 19(4):486–495, 2022. 13

[47] 奥利维尔·佩蒂、尼古拉·托姆、克莱门特·兰布尔、洛伊克·泰米尔、托比·柯林斯、*吕克·索莱尔。U-net变压器：基于自我与交叉注意力的医学图像分割。载于《医学影像中的机器学习：第12届国际研讨会，MLMI 2021，与MICCAI 2021同期举行，法国斯特拉斯堡，2021年9月27日》，会议论文集12*，第267–276页。Springer出版社，2021年。13

[48] Muhammad Imran Razzak, Saeeda Naz, Ahmad Zaib. 深度学习在医学图像处理中的应用：综述、挑战与展望. *生物应用中的分类：决策自动化*, 第323–350页, 2017. 8

[49] Michele Reibaldi, Nicola Cardascia, Antonio Longo, Claudio Furino, Teresio Avitabile, Salvatore Faro, Marisa Sanfilippo, Andrea Russo, Maurizio Giacinto Uva, Ferdinando Munno 等. 慢性中心性浆液性脉络膜视网膜病变中标准通量与低通量光动力疗法的比较：一项非随机临床试验. *眼科*杂志，149(2):307–315，2010。13

[50] 阿雷夫·米里·雷卡万迪、希玛·拉希迪、法里德·布赛德、斯蒂芬·霍夫斯、埃姆雷·阿克巴斯等。小目标检测中的Transformers模型：基准测试与前沿技术综述。arXiv预印本arXiv:2309.04902

，2023年。1

[51] Shamija Sherryl RMR 与 T Jaya. 肾肿瘤分割的多尺度与空间信息提取：基于上下文可变形注意力与边缘增强U-Net的方法. *Jour nal of Imaging Informatics in Medicine*, 37(1):151, 2024. 1

[52] 奥拉夫·罗内伯格、菲利普·菲舍尔与托马斯·布罗克斯。《U-net：用于生物医学图像分割的卷积神经网络》。载于《医学图像计算与计算机辅助介入——MICCAI 2015：第十八届国际会议论文集，德国慕尼黑，2015年10月5-9日》，第三卷 18，第234-241页。Springer出版社，2015年。1 , 2, 3

[53] Benjamin Rosman 与 Subramanian Ramamoorthy. 学习物体间的空间关系. *《国际机器人研究期刊》*, 30(11):1328–1342, 2011. 3

[54] 法哈德·沙姆沙德、萨尔曼·汗、赛义德·瓦卡斯·扎米尔、穆罕默德·哈里斯·汗、穆纳瓦尔·哈亚特、法哈德·沙赫巴兹·汗与傅华柱。医疗影像中的Transformers模型：一项系统综述。医学影像分析，88:102802，2023年。3

[55] 石达培、赵景远、王正红、赵恒、王俊斌、连宇波、Andrew F Burke. 基于时空自注意力变换器的电池电量状态估计模型. *《电子学报》*, 12(12):2598, 2023. 1

[56] 安珀·L·辛普森、米凯拉·安东内利、斯皮里东·巴卡斯、米歇尔·比莱洛、凯万·法拉哈尼、布拉姆·范·金内肯、安妮特·科普-施耐德、本尼特·A·兰德曼、赫尔特·利滕斯、比约恩·门泽等。用于分割算法开发与评估的大型标注医学图像数据集。 *arXiv预印本arXiv:1902*.09063，2019年。8

[57] Robert R Sokal 与 Neal L Oden. 生物学中的空间自相关性：1. 方法论. *林奈学会生物学杂志*, 10(2):199–228, 1978. 15

[58] 宋磊、夏敏、徐尧、翁立国、胡凯、林海峰、钱明。基于多粒度孪生变压器的遥感影像变化检测。*《人工智能工程应用》*，136:108960, 2024. 1

[59] Rafael Stahl, Alexander Hoffman, Daniel Mueller-Gritschneder, Andreas Gerstlauer, Ulf Schlichtmann. Deeperthings：资源受限边缘设备上的全分布式卷积神经网络推理. *《国际并行与并行化杂志》*, 49:600–624, 2021. 3

[60] 阿比谢克·塔库尔与苏丹苏·库马尔·米什拉。基于深度学习的自适应方法深度评估：利用传感器融合数据实现自动驾驶车辆障碍物检测。《人工智能工程应用》， 133:108550, 2024. 1

[61] 翁伟豪与朱欣。Inet：用于生物医学图像分割的卷积网络。 *《IEEE Access》*，9:16591– 16603，2021年。3

[62] 吴博与拉姆·内瓦蒂亚. 基于分组、合并及部件检测响应分配的多重部分遮挡物体检测与分割. 《国际计算机视觉期刊》, 82:185–204, 2009. 3

[63] 向天竹、夏桂松、张亮培. 基于微型无人机的遥感技术：方法、应用与展望. *IEEE地球科学与遥感杂志*, 7(3):29–63, 2019. 1

[64] 肖雄业、李世轩、黄鲁哲、刘耿硕、阮中坚、黄毅、常迪、Mykel J. Kochen-derfer、Paul Bogdan. 用于快速采样的多尺度生成模型 , 2024. 3

[65] 徐宇飞、张启明、张静、陶大成。Vitae：通过探索内在归纳偏置实现视觉转换器进阶。*神经信息处理系统进展*，34:28522–28535，2021。1

[66] 杨建伟, 李春源, 张鹏川, 戴西阳, 肖斌, 袁璐, 高建锋. 视觉变换器中局部-全局交互的焦点自注意力机制. *arXiv 预印本 arXiv:2107.00641*, 2021. 1, 3

[67] 姚山亮、关润伟、黄晓宇、李卓晓、沙向宇、岳勇、林恩基、徐亨俊、文家乐、朱晓辉等. 自动驾驶中基于雷达-摄像头融合的物体检测与语义分割：全面综述.*IEEE Transactions on Intelligent Vehicles,* 9(1):2094–2128, 2023. 1

[68] 张俊杰、张启明、龚永顺、张健、陈亮、曾丹。基于一致性约束多类注意力机制的遥感场景弱监督语义分割。*IEEE地球科学与遥感学报*，2024. 1

[69] 张正新、刘庆杰、王云红。基于深度残差U-Net的道路提取。*IEEE地球科学与遥感通讯*，15(5):749–753，2018. 3

[70] 赵杰、贾云、马林、于立丹. 基于自适应双流稀疏变压器网络的光学遥感图像显著目标检测. *《IEEE应用地球观测与遥感精选专题期刊》*, 17:5173–5192, 2024. 3

[71] 周博磊、赵航、Xavier Puig、Sanja Fidler、Adela Barriuso、Antonio Torralba. 基于ade20k数据集的场景解析. *见IEEE计算机视觉与模式识别会议论文集*，第633–641页，2017年. 5

附录

A. 代码与数据获取

实验运行代码详见：https://anonymous.4open.science/r/MaskUnet-736B.

B. 更多实验与讨论

B.1. λ对损失函数的影响

如式(7)所示，*参数*λ决定了交叉熵损失与实例对比损失的相对权重。我们探索了0.1至2.1的取值范围，对MaskAttn-UNet进行20个 epoch的训练，以观察不同λ设置对组合损失的影响。图4显示损失值呈持续下降趋势，*并在λ=0.5时*达到最低点。当λ值过小（例如低于0.3）时，实例对比项的重要性不足，导致实例分离效果减弱。相反，*过大的λ值*（高于1.0）会使交叉熵项失衡，导致像素级分类效果不佳。

这些结果表明，将 λ 设为 0.5 可在实例分割与全局分割中实现交叉熵损失与实例内对比损失的均衡组合。在此配置下，MaskAttn-UNet 既能实现可靠的像素级预测，又能有效区分实例，这对精确勾勒重叠物体和复杂场景结构至关重要。

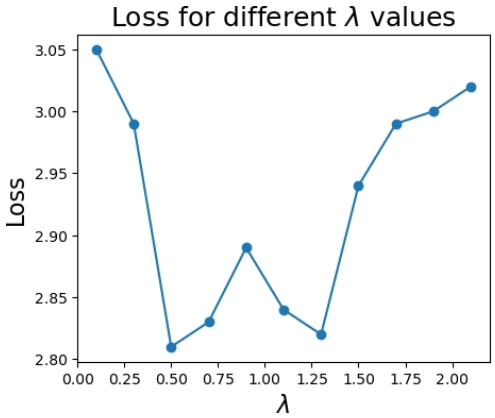

图4. **组合损失***随λ变化的***趋势曲线。**模型仅运行20个 epoch，未完成完整训练。最小损失*出现在*λ=0.5时。

尽管模型仅训练了20个 epoch，但组合损失的早期趋势清晰表明：此有限训练量足以评估 λ 的影响。$\lambda = 0.5$ 处出现的最小损失值表明该参数合理平衡了两个损失分量，为将其选作最优设置提供了坚实依据。进一步的训练和更精细的参数搜索预计将对这种最佳平衡进行微调，而非大幅改变。

B.2. 消融研究

MaskAttn 模块。为评估MaskAttn-UNet架构中Mask Attention模块的贡献，我们通过系统性移除这些模块并评估基线UNet性能开展了消融研究。两模型均在COCO panoptic val2017数据集上训练与测试，其性能指标详见表5。

模型	mIoU (%)	PQ (%)	AP (%)
MaskAttn-UNet	45.3	35.7	31.5
UNet	33.8	20.1	13.8

表5. MaskAttn-UNet与基线UNet在COCO panoptic val2017数据集上的性能对比。

集成掩码注意力模块后，所有评估指标均获得显著提升。具体而言，MaskAttn-UNet的平均交并比（mIoU）达到45.3%，较基线UNet的33.8%实现了**11.**5%的相对提升。在全局感知质量(PQ)方面，MaskAttn-UNet达到35.7%，较基线的20.1%实现15.6%的相对提升。此外，平均精度(AP)显著提升，MaskAttn-UNet达到31.5%，较基线的13.8%提升17.7%。mIoU、PQ和AP的显著提升表明，遮罩注意力模块使网络能够更有效地捕捉空间依赖关系和上下文信息——这些对精准分割至关重要。PQ和AP指标的显著增强表明，MaskAttn-UNet在复杂场景中识别并准确分割单个物体方面表现尤为出色，而基线UNet在此任务中存在局限性。

部分遮罩注意力模块。为评估MaskAttn-UNet中注意力机制的独立贡献，我们进行了两种模型变体实验：一种仅在编码器中集成遮罩注意力模块，另一种仅在解码器中应用该模块。表6展示了在COCO全视角val2017数据集上的实验结果。

尽管编码器专用变体相较于解码器专用变体在每帧性能上略有提升，但两种注意力模块在Mask

，但两种注意力模块发挥着互补作用，对MaskAttn-UNet的整体性能至关重要。编码器注意力模块在低分辨率图像中尤为有效，因其能增强局部细节与精细特征的提取能力，从而显著提升

变体	mIoU (%)	PQ (%)	AP (%)
仅编码器	38.1	24.3	18.8
解码器专用	36.7	23.6	17.0

表6. 仅在编码器或解码器中应用注意力机制的MaskAttn-UNet变体性能。

分割质量。另一方面，解码器注意力模块确保在重建过程中保持长程依赖关系，从而保留全局上下文信息。两种变体在mIoU上均超越传统UNet超过5%，PQ提升3%，AP提升5%。

完整MaskAttn-UNet模型通过在编码器和解码器中同步集成注意力机制，实现了局部细节增强与全局特征保留的协同优化，其性能显著超越各独立变体。该协同效应证实编码器与解码器注意力机制对提升分割性能至关重要——完整模型结果（mIoU=45.3%，PQ=35.7%，AP = 31.5%）。

总体而言，我们的消融研究表明：编码器注意力机制本身虽能带来显著优势，但同时整合编码器与解码器注意力模块对于捕捉完整的空间依赖关系至关重要，这能显著提升全局分割任务的性能。

模型	mIoU (%)	PQ (%)	AP (%)
自注意力UNet [47]	41.2	30.9	26.7
MaskAttn-UNet（本研究）	45.3	35.7	31.5

表7. COCO `panoptic val2017`数据集上Self-Attention UNet与MaskAttn-UNet的分割性能对比。

遮罩层。我们还希望探究遮罩层如何提升图像分割任务中的注意力模块。为此，我们在相同数据集上训练了自注意力UNet[47]，结果如表7所示。自注意力UNet达到mIoU 41.2%、PQ 30.9%及AP 26.7%。相比之下，通过在注意力模块中集成专用掩膜层的MaskAttn-UNet模型获得了显著提升的指标。掩膜层作为过滤器，既能抑制无关区域又能强化显著空间特征，从而解决了自注意力机制在捕捉精细局部细节时的普遍局限。该机制对低分辨率图像尤为有效——这类图像既需精准提取局部特征，又需保持长程依赖关系以维持全局上下文。

超低分辨率图像分割

在许多实际应用中，图像采集分辨率低于128×128。因此，我们测试了模型在超低分辨率下的表现，以确定可实现可靠分割的最小分辨率阈值。实际应用中，许多低成本无人机和相机采用64×64、64×48及32×32分辨率进行图像采集[46,49]。为建立基准对比，我们选取Mask2Former-R50和Mask2Former-R101作为对照模型，因其在128×128分割任务中表现相当。表8展示了这些模型在超低分辨率下的语义分割性能（mIoU）。值得注意的是，我们的模型能在分辨率为64×48分辨率下，基线模型能达到约100%的mIoU，而Mask2Former模型在此分辨率下仅能达到约10%的mIoU。在极低分辨率32×32下，所有模型均无法产生可靠的分割结果，表明该分辨率低于有效阈值。总体而言，这些结果表明我们的模型在基线方法已难以胜任的低分辨率下仍能保持分割能力，从而展现出其在资源受限环境中的鲁棒性。

方法	输入分辨率		
	64 × 64	64 × 48	32 × 32
Mask2Former-R50	31.4	8.7	1.3
Mask2Former-R101	33.5	11.2	1.9
MaskAttn-UNet（我们的）	41.3	17.1	2.2

表8. **不同输入分辨率下的语义分割性能（mIoU）。**当分辨率低于64×48时，我们的模型达到分辨率极限，而其他模型在64×64分辨率下仍表现吃力。

图5的可视化结果凸显了MaskAttn-UNet即使在极低分辨率下仍能生成有意义的语义分割结果的能力。在64×64分辨率（图5(a)）下，物体边界与主要结构仍清晰可辨，表明模型在输入尺寸缩减时仍能稳健保留关键语义信息。值得注意的是，在更低的64×48分辨率下（图5(b)），MaskAttn-UNet仍能成功识别主要物体，展现其在高度受限条件下捕捉粗略语义线索的潜力。

尽管在32×32分辨率（图5(c)）下的分割存在显著信息损失，模型仍能大致识别出主要物体，证实其利用有限像素信息的能力。这些定性结果强化了数值性能趋势，支持MaskAttn-UNet在计算资源或传感器能力严重受限的实际应用场景中的适用性。

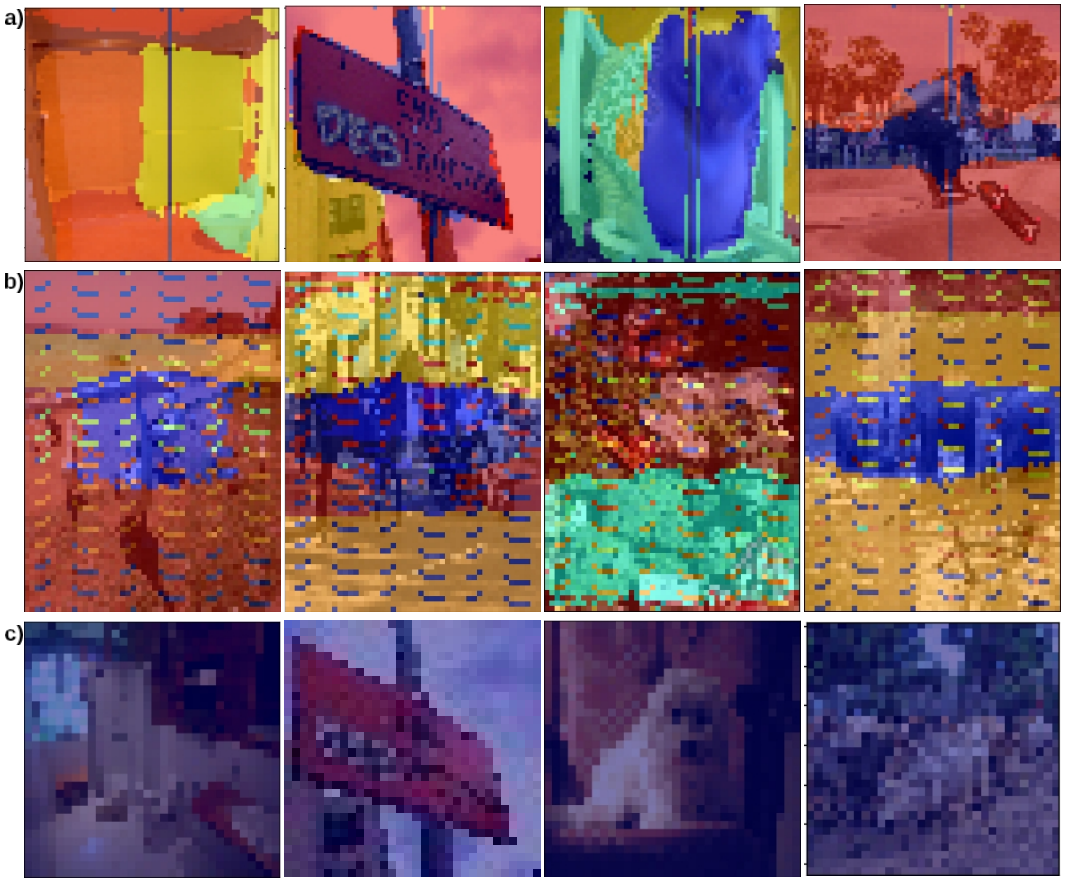

图5. **低分辨率分割结果可视化**：(a) 64×64分辨率语义分割样本；(b) 64×48分辨率语义分割；(c) 32×32分辨率语义分割。

B.3. 长程依赖性捕捉分析

为定量评估MaskAttn-UNet对长程依赖性的捕捉能力，我们分析了来自四个关键注意力模块提取的特征图：*att1*（早期编码器）、*att3*（底部编码器）、*att4*（底部解码器）*和att6*（顶部解码器）。针对每个模块，我们计算了赫斯特指数、趋势消除波动分析（DFA）的标度指数以及COCO `panoptic` val2017数据集的大型子集上的功率谱密度（PSD）。

赫斯特指数。赫斯特指数（H）用于量化时间序列数据中的长期记忆效应[28, 38]。它评估序列是否趋向均值回归或呈现持续聚类特征[7, 12]。形式上，H*值*取范围为0至1，其中：

- $H = 0.5$：代表无长程相关性的随机游走。
- $H > 0.5$：表明存在持久性行为，即高值倾向于跟随高值，低值倾向于跟随低值。
- $H < 0.5$：表明反持续性行为，即数值频繁交替变化。

去趋势波动分析（DFA）。DFA是一种通过多尺度波动分析识别非平稳信号中长程相关性的稳健统计方法[11, 26, 45]。主要步骤如下：

1. 通过从原始信号中减去均值并求累积和来计算积分序列。
2. 将该序列分割为等长段。
3. 对每个分段拟合并减去多项式趋势（通常为线性）。
4. 计算每个去趋势化区段的均方根波动值。
5. 分析分段长度与平均波动之间的标度关系。

DFA指数大于0.5表明存在持久的长程相关性。

功率谱密度（PSD）。PSD衡量信号方差（功率）在频率分量上的分布，揭示信号的关联结构[25, 39]。对于具有长程依赖性的信号，PSD通常遵循幂律关系衰减。

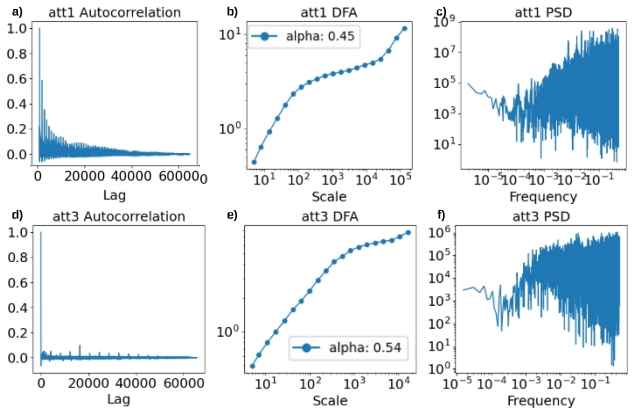

图6. **编码器中的长程依赖性分析。**(a) 早期编码器层（*att1*）的自相关图，展示相关性随滞后增加而衰减的趋势。(b) *att1的*延迟函数分析图，斜率反映缩放行为。(c) *att1的*功率谱密度图，呈现功率在不同频率上的分布。(d) **编码器各层赫斯特指数的汇总可视化。**(e) att1的功率谱密度图，展示功率在不同频率上的分布。(f) 编码器各层赫斯特指数的汇总可视化。(c) *att1的*功率谱密度(PSD)图，展示不同频率下的功率分布。(d) 编码器各层赫斯特指数的汇总可视化。(e) 编码器各层DFA指数的汇总可视化。(f) 编码器长程依赖性的综合指标概览。

相关性：

$$S(f) \propto \frac{1}{f^{\beta}} \tag{8}$$

*其中S(f)表示频率f处的*功率，*β参数*刻画相关强度。β值越高表明长程相关性越强。

自相关函数。自相关函数量化信号与其延迟版本的相似性，描述相关性随延迟增加衰减的速度[10, 20, 57]。具有长程依赖性的信号通常在自相关中呈现缓慢的幂律衰减。

表9汇总了各注意力模块的平均指标：

注意力模块	赫斯特指数	DFA指数
att1（早期编码器）	0.628	0.459
att3（底部编码器）	0.594	0.538
att4（底部解码器）	0.597	0.501
att6（顶部解码器）	0.694	0.657

表9. 不同注意力模块的平均赫斯特指数与DFA指数

如表9所示，早期编码器层（*att1*）呈现0.628的赫斯特指数，表明编码初始阶段特征图具有中等程度的持久性。然而对应的DFA指数略低（0.459），说明虽然存在局部结构，但局部波动仍较为显著。

在编码器底部（*att3*），赫斯特指数小幅下降至0.594，而DFA指数上升至0.5379。这种变化表明最深层的编码器整合了更多上下文信息，从而产生更强的长程相关性，尽管仍接近0.5阈值。

解码器早期阶段（*att4*）表现与底层编码器相似，赫斯特指数为0.597，DFA指数为0.501。这些数值表明该阶段解码器持续保留中程依赖性，但尚未完全强调全局一致性。最显著的是顶层解码器（*att6*）在所有模块中表现出最高数值：赫斯特指数达0.694，DFA指数达0.657。这些结果表明最终解码器整合了覆盖整幅图像的更广阔上下文，从而捕捉到更强劲的长程依赖关系。图7进一步说明了这一点，该图展示了解码器阶段特征相关结构的演变。

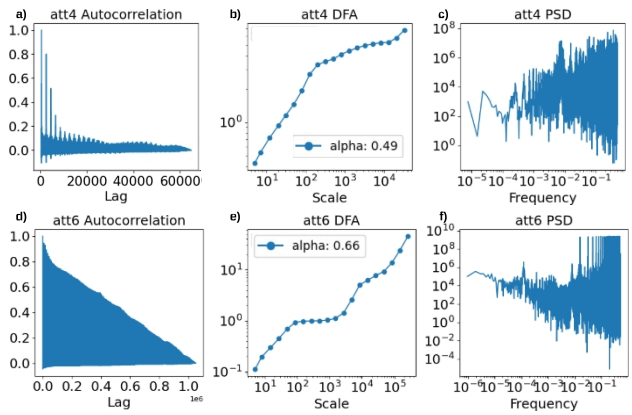

图7. **解码器中的长程依赖性分析。**(a) 底层解码器层(*att4*)的自相关图，展示相关性的衰减过程。(b) *att4的*DFA图，斜率反映缩放指数。(c) *att4的*PSD图，呈现频域特征。(d) 解码器各层赫斯特指数的汇总可视化。(e) DFA指数在解码器层间的汇总可视化。(f) 解码器长程依赖性的综合指标概览，突出顶层解码器(att6)的高持久性。(e) 解码器各层DFA指数的汇总可视化。(f) 解码器长程依赖性综合指标概览，突出显示顶层解码器层(*att6)*的高持久性。

图6和图7分别展示了编码器和解码器中长程依赖性的可视化特征。编码器（图6）表明，尽管早期层捕获了大量局部细节，但全局结构在网络更深层得到强化。另一方面，解码器（图7）揭示顶层通过有效整合局部信息，生成更具全局一致性的特征图。整体结果表明，MaskAttn-UNet在整个网络中逐步提升了长程依赖捕捉能力

，其中顶层解码器层（*att6*）展现出最强持久性。该能力对分割任务至关重要，它使模型能够整合远距离区域的上下文线索，同时保留精细细节。